

FDA 老药新靶点：当前1000候选的真实完整漏斗

已有1000由 ConPLEx/结构可做性/Boltz-2/V5硬合同产生；GNINA是后来新增的审计分支，不参与这批1000的生成

一、原始输入与边界		
药物输入：FDA_approved_small_molecules_2005_2026_with_structures.xlsx		靶点输入：druggable_proteome_chembl(1).xlsx
915 个药物ID；主表23列，含名称、上市年份、途径、原适应症、原标签靶点、action type、MoA、SMILES、ChEMBL ID和物化性质。	作用：定义本项目2005–2026 FDA起始药物清单。 边界：不等同于FDA全历史全部小分子。	5,307 条accession记录；含UniProt、gene、序列、target class、模态和临床阶段；折叠为 892 genes / 891条可用唯一序列。
		作用：定义ChEMBL-MoA人源成药锚点边界；后续以ChEMBL 37和Open Targets 26.06补充审计。 边界：不是全部人类蛋白。

二、实体级筛选：如何得到334,749个正式物理pair

药物轴：915 ID → 750项目ID → 723计算结构		靶点轴：5,307记录 → 892 genes → 463序列	三个不同的空间
915 → 779	只保留明确直接作用action type。 移出136：空标签118；releasing 5；sequestering 3；chelating 2；binding 2；substrate 2；reducing 2；cross-linking 1；disrupting 1。原因：不能定义标准人源蛋白直接亲和或主要为间接/物理/化学作用。	5,307 → 892 按gene/canonical target折叠accession。 IFNA1缺序列，因此最初序列计算使用891条唯一序列。	原始序列计算空间 815,265 915×891；最初全空间ConPLEx与召回审计。
779 → 750	排除29条不适合当前直接target-engagement的药物。 含广谱DNA/reactive、病原体/非人主机制、超大/肽样天然产物等；详细逐药审计单保留。5个边界药物经人工复核恢复。	892 → 462 限定非GPCR、可做直接小分子target-engagement。 移出430：GPCR/膜受体205；分泌/表面/黏附/结构类127；unclassified、缺标准assay或直接小分子/结构支持不足98。GPCR单列未来队列，不是认为其不可成药。	冻结ID审计空间 347,250 750×463；保留FDA/ChEMBL ID用于标签和文献追溯。
750 → 723	同一计算结构折叠27个重复表示。 RDKit canonicalization + largest fragment + Uncharger；这是盐/对离子计算标准化，不同药代active metabolite判定。	462 → 463 口袋共识后恢复BCL2L10。 最终：enzyme234、kinase105、ion channel53、nuclear/epigenetic41、transporter27、other3；冻结sequence key、UniProt和assay family。	正式物理设计空间 334,749 723×463；重复盐型/结构不重复计算，现有1000漏斗的正式科学起点。

三、已完成主漏斗：334,749 → 3,000 → 1,000

步骤	输入 → 输出	实际采用的筛选规则	这样筛的原因与严格解释	状态
1. 物理准入硬门	334,749 → 254,694 唯一物理pair 对应ID行：347,250→264,352	结构必须为A/B/C；靶点满足direct-SM标准；排除exact known pair和保守family/rediscovery风险。该阶段没有使用ConPLEx Top100或绝对分数硬删除。	先保证药物、靶点、结构和新颖性边界正确。移出的80,055个物理pair进入known/control、family review或结构不可判定空间，不代表“不结合”。	完成
2. ConPLEx排名审计	334,749 → 71,861 药物内Top100 ∩硬门 = 48,972	对每个模型配体在463个靶点中计算ConPLEx排名；Top100约占物理空间21.5%。与物理准入硬门交集为48,972。该数字用于定义优先区域和审计覆盖。	ConPLEx适合低成本大空间富集，但不是亲和常数。严格说，原V4 Top3000代码没有把Top100写成硬门；事后审计显示3,000中2,994条位于Top100，6条边界项未进入V5最终1000。	完成 召回/预算
3. pre-Boltz 3,000	264,352 ID eligible → 3,000 436 drugs / 215 targets	预分数由ConPLEx、口袋先验、Open Targets tractability、药物/实验可行性和新颖性组成；再限制每药≤12、每靶点≤32、每骨架≤50及靶点家族上限。	无法对25万级候选全部运行高成本复合物模型；因此用低成本证据分配Boltz预算，并防止少数药物、靶点或骨架垄断。3,000是计算预算，不是自然质量阈值。	完成
4. Boltz-2与pose审计	3,000 → 3,000完成 pose A 1,923 / B 673 / C 404	3,000条全部使用签名输入完成Boltz-2结构与affinity输出；比较两个条件结构样本的配体RMSD、质心和界面残基；同步审计序列、模板、化合物责任和同源风险。	增加pair级三维与条件pose信息。此处Boltz A/B/C和affinity仍是计算优先级，不是实验binder概率；后续发现140条模板/序列错配，必须硬排除。	完成
5. V5统一硬合同	3,000 → 2,860 → 2,750 → 2,561 → 2,201 → 1,308	依次要求：序列/模板一致（去140）；既有审阅无矛盾、D级、数据库失败或exact nonbinding（去110）；药物/模型配体无前药活性物种待重抛（再去189）；pose为A/B（再去360）；Boltz affinity达到Known96同实验家族阳性q10下限（剩1,308）。	这些条件不可由其他高分补偿，因此采用fail-closed硬门。Known96只有阳性、没有可靠阴性；q10只表示“不低于阳性参照下限”，不能估计precision、FDR或真实结合概率。	完成 主候选池
6. 物理排序与多样性	1,308 → 1,000 321 ligands / 163 targets / 281 scaffolds	V5 pair physics score = 70% Boltz校正轴 + 30% ConPLEx复合轴；按分数排序后限制每药≤6、每靶点≤14、每骨架≤20及家族集中度。结果审计：1,000/1,000均在ConPLEx药物内Top100。	从达到统一底线的候选中保留较强pair信号，同时保证广谱发现覆盖。固定1,000是实验/审阅容量目标，不是模型产生的自然真假边界。	完成 正式1000

1,000	当前完成的计算储备包	GNINA应放在这里：后来新增的后验审计/下一版重建分支
	生成文件：FINAL1000_STRENGTHENED_V5.csv；相对V4保留735条、替换265条。强度分层为A 500、B 292、C 208，含义分别为达到Known96阳性的median、q25和q10；不是结合概率。 完整审阅表：FINAL1000_FULL_DEEP_REVIEWED_V7.csv；pair集合与V5完全一致，增加文献、活性物种、暴露、assay和疾病注释，不改变1000条的生成血缘。	现有1000形成后，为补足“Known96只有阳性、无法评价特异性”的缺口，另建9,199条同靶点正负对照：417个靶点完成GNINA，349个可评估，157个预注册通过、95个强通过，并形成7,370条强校准未来计算队列。 GNINA没有参与上述V5 1000的筛选或排序；7,370也不是这1000的上游。它只用于审计旧方法并重建下一版候选。

汇报主句：当前1000的真实路线是“来源与实体冻结 → 物理准入 → ConPLEx/结构/可做性预选 → 3,000条Boltz精修 → V5序列/审阅/活性物种/pose/阳性下限硬合同 → 1,308 → 多样性收敛到1,000”；GNINA是后续审计，不属于该血缘。

关键血缘：TOP100_SCOPE_INTERSECTION_AUDIT.json； formal_completion_summary_v4_complete.json； STRENGTHENED_V5_SUMMARY.json； FINAL1000_STRENGTHENED_V5.csv SHA-256 4f22a26702d6d3e3...