

BioMaster 当前架构

V3 底座 + J 双向增量模块 · J_old_relation_pretrained · 2026-09-06

冻结底座 (训练 J 时) 可训练 J 参数 固定输入 / 缓存

01 输入与训练期证据

分子、蛋白和可追溯实测关系

药物输入

SMILES → 标准化分子
Morgan 2048维 / BerMol 768维

P

靶点输入

蛋白序列 + 靶点家族
ProtBERT 1024 + legacy ESM2 1280
完整序列 ESM2 均值 1280维

P

正负支持库

仅使用训练期明确实测标签
按当前靶点检索 Morgan 近邻
正样本 / 负样本分别 Top 16
Tanimoto 相似度 + 有效掩码
排除查询分子自身及其别名
另提取 8 项相似度 / 可用性统计

E

P: 公共预训练全局特征缓存
E: 同一支持库的直接证据统计
同名圆点表示相同输入来源

02 V3 底座 × 2

两个独立种子; 此处展开单个底座

模态投影与蛋白融合

Morgan → 药物向量 d: 192维
ProtBERT + ESM2 门控融合 → t: 192维

全局药物-靶点交互

双向 FiLM 调制 + 低秩双线性 (rank 48)
拼接 d、t、逐元素积 / 差、双线性、家族
MLP 256 → 共享头 + 6 专家路由 + 余弦项
并行投影 → 交互隐状态 h_i: 192维

按查询聚合正负支持

共享药物编码 → 正 / 负分离的注意力池化
学习支持门控 g 和分数修正 Δsupport
z_i = z_global + g × Δsupport

两个底座汇总

基础分数 z_base = (z1 + z2) / 2
H = concat(h1, h2): 384维

H 来自支持融合前的全局交互投影
训练 J 时底座与特征缓存均不更新

03 J 增量模块 × 3

三个独立种子; 此处展开单个模块

全局残差 MLP

输入: H 与 z_base / 5
385 → 96 → 2
LayerNorm / GELU
Dropout 0.1
输出: rMLP (双向)

预训练向量交互

BerMol: 768 → 48
完整 ESM2: 1280 → 48
拼接 d'、t'、
d' ⊙ t'、|d' - t'|
192 → 64 → 2
输出: rpre (双向)

有符号直接证据

从 E 取有效正 / 负
最大相似度 s_pos / s_neg
使用 s 与 s² 两项
非负权重分别学习
正证据 - 负证据
输出: rE (双向)

零初始化、有界的双向修正

$\Delta = 4 \tanh((rMLP + rpre) / 4) + 6 \tanh(rE / 6)$
两个输出分量分别服务药→靶、靶→药

跨 3 个增量模块求均值, 再加回冻结基础分数

$z_dir = z_base + \text{mean}(\Delta1_dir, \Delta2_dir, \Delta3_dir)$

药 → 靶点排序

固定药物, 按目标集合排序

靶点 → 老药排序

固定靶点, 按老药集合排序

训练方式

① 先训练 V3 底座

明确正负标签 BCE + 按药物均衡采样
得到两个独立种子的底座权重

② 冻结底座, 训练 J

0.25 × 实测 BCE + 0.5 × 双向关系检索损失
未知配对进入检索分母, 不伪装成生化阴性

③ 验证集选择, 再冻结测试

按双向 AP / Recall 选轮数, 保留实测 AP 约束
最终输出是排序 logit, 尚非校准概率

当前 J 实体划分; 471 条训练老药药理关系; 用于本轮 KIRHub 评分。

时间 J 同拓扑、独立权重; ≤2022 年实验关系重训, 815 条老药阳性用于检索监督; 测试 2023-2025。

当前边界: 全局向量交互; 原子-残基交叉注意力、三维口袋 / DrugCLIP 分支未在该候选中启用。

评分覆盖: 720 老药 × 384 核心靶点; 评估时按具体协议筛选候选。图示为已实现升级候选, 生产默认尚未替换。