

888个成药锚点 已知口袋图谱与P2Rank审计

整合实验结构、专类口袋数据库与Open Targets tractability，并在统一UniProt残基坐标上回顾性评价AlphaFold/P2Rank预测。

737 / 888

实验口袋覆盖

canonical残基可用于比较

579

高置信实验口袋

K1药物映射 + K2专库确认

52.4%

P2Rank Top1

保守代表口袋综合匹配

实验已知口袋与计算预测口袋分层保存。数据库覆盖不等于可直接对接，P2Rank找回历史位点也不等于未知药物-靶点pair会结合。

一、结论

人源蛋白当然存在大量已知口袋数据，但不存在一个“对所有蛋白完整、全部是药物口袋、可直接用于对接”的单一数据库。本轮已把可批量审计的核心实验来源统一到888个ChEMBL-MoA靶点，并将P2Rank从“口袋证据”重新定位为“无配体结构上的预测工具”。

737个

至少一个通过残基数、配体类型和canonical映射门槛的实验口袋。

579个

具有药物映射或BioLiP2/scPDB/KLIFS/GPCRdb专库支持的高置信实验口袋。

151个

没有合格实验口袋；其中76个只有P2Rank A/B预测，可进入探索层。

二、数据源与职责

来源/方法	提供什么	本项目如何使用
PDBe/SIFTS	实时实验结构配体接触残基，并映射到canonical UniProt编号	实验事实层；含溶剂、离子和冗余，必须过滤
BioLiP2	半人工筛选生物学相关配体，并汇总亲和来源	为PDBe位点增加生物学相关性与亲和注释
scPDB 2017	PDB中药物样/可配体化位点及相互作用指纹	历史专库确认；版本较旧，不负责新增结构
KLIFS	激酶口袋、构象、质量、配体和85位点标准化	激酶专用实验结构确认
GPCRdb	GPCR结构状态、配体和通用编号相互作用残基	GPCR专用实验结构确认
Open Targets 26.06	small-molecule tractability桶	靶点级可做性标签，不是残基级口袋真值
P2Rank 2.6-alpha	在AlphaFold结构上预测口袋中心、残基、分数和概率	无配体预测层；需用实验位点回顾性校验

PDBe与RCSB均基于全球PDB实验结构，本项目以PDBe API和SIFTS的UniProt残基映射为主干，避免重复抓取同一PDB事实。PDBbind、Binding MOAD、BindingDB的亲和注释通过BioLiP2字段纳入，不将其误作新的口袋几何来源。canSAR原始API需要授权，本包仅保留Open Targets公开tractability桶，不伪造残基级canSAR数据。

三、收集与标准化漏斗

PDBe任意实验配体接触位点		769 · 86.6%
统一后合格实验口袋		737 · 83.0%
K1+K2高置信实验口袋		579 · 65.2%
K1药物映射高质量口袋		225 · 25.3%

• PDBe共返回95,209条target-PDB-chain-ligand接触记录。

- 去除溶剂/添加剂、离子/极小片段、少于3个接触残基以及canonical序列映射不可靠记录后，保留38,850条基准实例。
- 按靶点与canonical残基集合折叠重复晶体，得到35,269个实验接触残基集合；该数字仍代表不同配体接触集合，不应解释为35,269个彼此独立的物理腔体。
- 最终比较以729个同时具有合格实验口袋和精确AlphaFold模型的靶点为分母；另8个实验口袋靶点没有精确AF结构，不进入P2Rank性能分母。

四、各来源覆盖

来源/口径	靶点数	占888
PDBe原始任意配体接触位点	769	86.6%
BioLiP2原始项目匹配	659	74.2%
KLIFS项目结构覆盖	111	12.5%
GPCRdb项目结构覆盖	125	14.1%
scPDB链+配体精确映射	207	23.3%
PDBe/统一实验口袋	737	83.0%
PDBe药物映射口袋	227	25.6%
统一基准内BioLiP2支持	563	63.4%
统一基准内BioLiP2带亲和记录	327	36.8%
统一基准内scPDB支持	202	22.7%
统一基准内KLIFS支持	109	12.3%
统一基准内GPCRdb支持	118	13.3%
Open Targets结构配体标记	603	67.9%
Open Targets高质量口袋标记	222	25.0%
Open Targets中质量口袋标记	75	8.4%

不同来源并非互斥。PDBe负责完整实验事实，BioLiP2负责生物学相关性，scPDB/KLIFS/GPCRdb负责专库语境；重复支持用于审计可信度，不按“票数”直接生成成分。

五、P2Rank如何比较

残基重叠 实验接触残基召回 $\geq 25\%$ ，或Jaccard ≥ 0.10 。它允许预测口袋边界与实验接触集合不完全一致。	几何中心 将实验接触残基映射到同一AlphaFold模型，计算其CA中心与P2Rank中心距离；同时报告 $\leq 4\text{ \AA}$ 和 $\leq 8\text{ \AA}$ 。
---	--

为控制热门靶点的重复结构偏倚，主结果采用“每个靶点只保留一个最高证据代表口袋”。“命中任意历史口袋”另行保存，只作为较宽松上界。

评估口径	分母	匹配数	匹配率	Wilson 95%区间
全部代表口袋 Top1	729	382	52.4%	48.8%–56.0%
全部代表口袋 Top3	729	477	65.4%	61.9%–68.8%
K1药物口袋 Top1	223	164	73.5%	67.4%–78.9%
K1药物口袋 Top3	223	186	83.4%	78.0%–87.7%

52.4%不是P2Rank的未知靶点成药成功率。它表示在已有实验口袋的蛋白上，Top1预测与一个预先选定的代表口袋满足本项目的残基或 $8\text{ \AA}$ 几何规则。它不评价具体FDA药物是否结合，也不等于Kd、precision或湿实验命中率。

结果为何有宽窄两个数

- “任意历史口袋” Top1综合匹配为529/729（72.6%），适合回答P2Rank是否找到过该靶点的某个已知位点，但对多口袋热门蛋白乐观。
- “单一代表口袋” Top1为382/729（52.4%），更保守；Top3升至477/729（65.4%）。
- 严格中心 $\leq 4\text{ \AA}$ 在代表口袋上为138/729（18.9%）；该指标对长形口袋和接触集合边界敏感，因此与残基重叠并列报告，不单独定义成功。

六、P2Rank等级是否有信息

P2Rank等级	已知口袋靶点数	Top1匹配数	Top1匹配率
A 高置信	501	340	67.9%
B 中等置信	73	25	34.2%
C 弱证据复核	69	10	14.5%
D 低置信	51	7	13.7%
D 未预测出口袋	35	0	0.0%

A级显著优于B/C/D，说明此前的P2Rank等级具有回顾性区分信息；但B以下下降明显。35个已有实验口袋的靶点被P2Rank判为无口袋，这是明确的预测漏检，不应由其他总分补偿。

七、Open Targets为何看起来覆盖较低

- **Structure with Ligand:** 603个，其中586个被本轮实验口袋基准覆盖。
- **High-Quality Pocket:** 222个，其中220个有本轮实验口袋；它是严格tractability桶，不是“所有已知口袋”。
- **Med-Quality Pocket:** 75个，其中72个有本轮实验口袋。
- 因此Open Targets的222不是说只有222个蛋白有口袋，而是只有222个满足其高质量小分子tractability定义。PDBe/BioLiP2的覆盖更宽，但也包含底物、辅因子、片段和非首选结构。

八、888个靶点的最终口袋决策分层

决策层	靶点数	占888
E2_专库确认实验口袋	354	39.9%
E1_药物映射实验口袋	225	25.3%
E3_实验药物样口袋待复核	124	14.0%
P1_无实验口袋_P2Rank_AB探索	76	8.6%
P2_无实验口袋_P2Rank低置信或无口袋	70	7.9%
E4_功能配体或片段口袋待复核	34	3.8%
P3_无实验口袋且无精确AF结构	5	0.6%

结构筛选使用规则

1. E1/E2共579个：优先选实验holo结构和对应口袋；P2Rank只用于检查是否一致、寻找备选或潜在变构位点。
2. E3/E4共158个：先人工核验配体身份、辅因子/底物语境、构象和口袋是否适合项目分子，再决定是否对接。
3. P1共76个：没有合格实验口袋，仅有P2Rank A/B；必须增加另一口袋预测、保守位点或结构文献支持后才能进入高成本计算。
4. P2/P3共75个：当前不应作为标准结构筛选对象，先补结构、构象或口袋证据。

九、对项目流程的直接修正

已知口袋优先级：实验holo口袋 > 专库确认实验口袋 > 一般实验药物样口袋 > P2Rank A/B共识预测 > 低置信预测。P2Rank不再作为888个靶点统一、同等级的口袋来源。

- 后续对接应按具体target-construct-structure-pocket-protocol组织，而不是只按gene或AlphaFold Top1口袋组织。
- 同一靶点的正构、变构、辅因子和蛋白界面口袋必须分开；已知药物口袋不代表所有候选药物都能结合。
- 这次回顾性结果验证的是“口袋定位工具的适用范围”，没有验证任何drug-target pair。
- 对于没有已知口袋的151个靶点，不能用“无数据库记录”推导“没有口袋”；只能标记为缺少可审计实验真值。

十、局限与边界

- 实验结构存在构建体、亚型、缺失区段、辅因子和构象状态差异；canonical残基统一不能消除结构状态差异。

- PDBe配体接触是实验事实，但自动等于药理相关位点；因此设置K1-K4分层。
- scPDB版本较旧，只作为历史专库证据；新增PDB由实时PDBe/BioLiP2补足。
- AlphaFold为单体预测结构；复合物界面、膜环境、cryptic pocket和induced fit可能无法由静态P2Rank覆盖。
- 本报告不声称“已收集世界上每一个私有或授权口袋库”，而是完成主要公开、可批量复现和可映射的数据源。

十一、正式文件

文件	用途
TARGET_POCKET_DECISION_PACKAGE_888.csv	每靶点口袋证据、P2Rank比较和使用策略
CHEMBL37_HUMAN_SINGLE_PROTEIN_MOA_TARGETS_888_POCKET_ENHANCED.csv.gz	888靶点全字段增强主表
CHEMBL37_888_KNOWN_POCKET_ATLAS_AND_P2RANK.xlsx	老师/实验组可读工作簿
KNOWN_POCKET_VS_P2RANK_INSTANCE_COMPARISON.csv.gz	每个实验残基集合与P2Rank逐项比较
P2RANK_REPRESENTATIVE_POCKET_COMPARISON_ZH.csv	保守代表口袋统计
P2RANK_COMPARISON_COUNTS_ZH.csv	任意历史口袋的宽松上界统计

数据日期：PDBe、KLIFS、GPCRdb为2026-08-04实时抓取；Open Targets为26.06；scPDB为2017公开版本；P2Rank为本地2.6-alpha结果。所有比例均由CSV/JSON自动生成。